Documentation Projet Datamining : Profil Client Aramisauto

Yuna Cann, Noa Delaporte, Sarah Scalart - M1 MAS 2025 / 2026

1 Présentation Globale du Projet

Aramisauto souhaite mieux comprendre le profil de ses clients pour optimiser sa stratégie marketing. Pour répondre à ce besoin, nous avons analysé les données internes afin d'identifier les comportements et les préférences des clients.

L'objectif principal était de transformer un jeu de données transactionnel brut en insights actionnables pour les équipes marketing et commerciales, à travers un dashboard interactif.

2 Guide d'Utilisation de l'Application

L'outil a été développé en Python, en utilisant le framework Streamlit pour garantir une interface utilisateur intuitive et facile d'accès pour les équipes métier.

Pré-requis et Lancement :

1. Assurez-vous d'avoir Python 3.9 (ou une version supérieure) installé sur votre machine.
2. Installez les dépendances requises via la commande : `pip install -r requirements.txt`. Les bibliothèques principales incluent `streamlit`, `pandas`, `plotly`, `scikit-learn`, `prince`, et `scipy`.
3. Placez le fichier de données `df_master.csv` dans un dossier `data/` situé à la racine du projet.
4. Lancez l'application avec la commande : `streamlit run app.py`.
5. Un onglet s'ouvrira automatiquement dans votre navigateur par défaut. Vous pourrez utiliser le menu latéral gauche pour appliquer des filtres dynamiques (âge, genre, budget, etc.) sur l'ensemble de l'analyse.

3 Méthodologie et Choix Statistiques

Afin d'assurer la clarté et la pertinence des résultats, nous avons privilégié une diversité de visualisations interactives (histogrammes, graphiques en barres, boîtes à moustaches).

L'analyse s'articule autour de trois hypothèses marketing majeures, validées par des tests statistiques :

— **H1 : Le prix du véhicule augmente avec l'âge.**
Testée via une **Corrélation de Pearson**.
Résultat : La corrélation positive est confirmée, justifiant un ciblage premium sur les segments plus âgés, qui disposent généralement d'un pouvoir d'achat supérieur.

— **H2 : Le genre influence la catégorie de véhicule.**
Testée via un **Test du Chi-deux**.
Résultat : L'association significative est validée, ouvrant la voie à des campagnes segmentées par genre en fonction des catégories de véhicules (SUV, citadines, etc.).

— **H3 : L'âge prédit le mode de financement.**
Testée via un **Test du Chi-deux**.
Résultat : Validation d'un glissement de la LOA (très présente chez les jeunes) vers le paiement comptant (majoritaire chez les seniors).

4 Difficultés Rencontrées et Pivots Stratégiques

Lors de la phase de modélisation, notre objectif initial était de proposer un onglet de segmentation automatique par clustering (utilisant K-Means et KNN). Cependant, nous avons fait face à plusieurs défis techniques :

— **Qualité insuffisante du clustering :** Les scores de silhouette obtenus avec K-Means sur les caractéristiques disponibles restaient faibles ($< 0,25$). Cela indique un chevauchement important entre les clusters et une absence de séparation naturelle dans les données.

— **Encodage des variables catégorielles :** La coexistence de variables continues (comme l'âge et le prix) et de variables catégorielles multi-valuées (énergie, catégorie, boîte de vitesse) rendait le calcul de la distance euclidienne mathématiquement peu adapté.

— **Interprétabilité des clusters :** Les groupes produits par l'algorithme ne correspondaient pas à des profils marketing cohérents et actionnables. L'onglet aurait donc été peu utile pour une équipe commerciale.

Solution adoptée : Face à ces difficultés, nous avons fait le choix de remplacer l'onglet de clustering par une Analyse des Correspondances Multiples (ACM - Onglet 3). Cette méthode offre une visualisation des associations entre modalités beaucoup plus stable et interprétable. Nous avons également développé un moteur de recommandation KNN (Onglet 4), qui valorise l'algorithme de voisinage dans un cadre fonctionnel et concret.

5 Limites de l'Approche Actuelle

Bien que l'application soit pleinement fonctionnelle et réponde aux objectifs, elle présente certaines limites qu'il est important de garder à l'esprit :

— **Données statiques :** Le fichier `df_master.csv` est chargé une seule fois à l'initialisation. L'application ne dispose pas d'une connexion à une base de données en temps réel. Par conséquent, les observations peuvent devenir obsolètes dès qu'une nouvelle campagne modifie les comportements d'achat.

— **Recommandation KNN et données froides :** La recommandation repose exclusivement sur la similarité avec des transactions passées. Pour des profils très atypiques (budget extrêmement élevé, préférence très rare), le voisinage peut s'avérer peu représentatif et les recommandations potentiellement moins pertinentes.

— **Limites de l'ACM :** L'ACM réduit la dimensionnalité pour faciliter la lecture, mais les deux premières dimensions n'expliquent qu'une partie de la variance totale. Des associations importantes peuvent exister dans des dimensions qui ne sont pas représentées sur le graphique (biplot).

6 Axes d'Amélioration et Recommandations

Pour faire évoluer ce projet et maximiser son impact sur la stratégie d'Aramisauto, nous recommandons les développements suivants :

— **Enrichissement des données externes :** Il serait pertinent d'importer des données démographiques (pour mieux comprendre les segments de clients régionaux) et des données économiques (pour anticiper l'évolution du pouvoir d'achat) afin de les croiser avec nos données internes.

— **Industrialisation de l'outil :** Mettre en place une connexion directe entre une base de données cloud (Data Warehouse) et l'interface utilisateur. Cela garantirait que l'équipe marketing travaille toujours sur des données à jour.

— **Automatisation marketing :** Relier directement les résultats du moteur de recommandation (Onglet 4) au CRM de l'entreprise pour générer automatiquement des e-mails personnalisés ou des scripts d'appels pour les conseillers de vente.